

Multilevel metoder för hierearkisk data (1)

Introduktion

Tänk dig ett scenario där du genomför en analys på 50 personer och får ett p-värde som ligger nära signifikansgränsen, säg 0.08. Enligt statistisk teori minskar p-värdet i regel när urvalsstorleken ökar, eftersom osäkerheten minskar.

Men tänk nu att du **duplicerar din observationer** så att du får 100 personer istället för 50 - alltså varje observation förekommer två gånger. Detta borde väl leda till ett lägre p-värde? Svaret är **ja - men det är också ett problem.**

När man beräknar ett p-värde undersöker man, i princip, **hur sannolikt det är att observera samma resultat igen** givet att nollhypotesen är sann. Om man duplicerar datamaterialet blir sannolikheten att se samma resultat i princip 1, eftersom observationerna inte längre är oberoende. Man har alltså brutit mot ett av de viktigaste antaganden inom klassisk inferensstatistik: **antagandet om oberoende observationer.**

I verkligheten skulle ingen duplicera sitt datamaterial medvetet, men ibland händer något **liknande** utan att man märker det. Tänk att du får frågan "*Vilken fetthalt på mjölk tycker du är godast?*". Om man frågar dig och en slumpmässig person på datan kommer era svar sannolikt skilja sig något. Men om man istället frågar **dig och ditt syskon**, är chansen stor att ni svarar likadant. I praktiken har man alltså "kopierat" en observation - vi har infört **beroende** i datan.

Detta fenomen uppstår ofta i verkliga studier. Till exempel, om man samlar in data från flera **elever i samma klass** eller **barn i samma familj**, tenderar svaren att likna varandra. Man säger då att observationerna är klustrade - de bildar små grupper där individer delar miljö, påverkan eller erfarenheter.

Om man analyserar sådana data med vanliga metoder (som OLS regression), som förutsätter oberoende observationer kan resultaten bli **missvisande.**

Standardfelen underskattas, p-värdena blir för små, och vi riskerar att dra falska slutsatser.

Därför behövs **hierarkiska modeller (multilevel models)** eftersom de tar hänsyn till att data kommer från flera nivåer, och att observationer inom samma grupp tenderar att korrelera.

Bakgrund - vad är hierarkisk data?

Hierarkisk (eller klustrade) data betyder att observationer är grupperade i flera nivåer. Exempelvis:

Exempel	Nivå 1	Nivå 2	Nivå 3
Skolor	Elever	Klasser	Skolor
Familjer	Barn	Familjer	
Företag	Anställda	Avdelningar	Företag

Dessa nivåer gör att observationer inom samma grupp inte är oberoende. Elever i samma klass, syskon i samma familj eller anställda på samma kontor tenderar att likna varandra **detta medför att residualerna blir korrelerade!**

Varför vanliga modeller (OLS) inte fungerar

Den vanliga regressionsmodellen med OLS skattning antar att alla observationer är oberoende:

$$y_i = \beta_0 + \beta_1 x_1 + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)$$

Men om observationerna kommer från grupper (T.ex elever inom skolor) bryts detta antaganden. Konsekvens blir:

1. Underskattade standardfel.
2. För små p-värden.
3. För stor risk för falska signifikanta resultat (typ 1 fel).

Det är alltså som att **duplicera** sin data - du får skenbart mer information än du egentligen har.

Vad hierarkiska modeller gör annorlunda

Hierarkiska modeller respekterar datans struktur genom att lägga till **slumpmässiga effekter (random effects)** som fångar variationen mellan grupper. De låter t.ex interceptet (och ibland lutningen) variera mellan grupper.

Allmän form: General Linear Mixed Model (GLMM)

$$Y = X\beta + Zu + e$$

där

- $X\beta$ = fixed effects (de "vanliga" regressionskoefficienterna)
- Zu = random effects (variation mellan grupper).
- e = residualer inom grupper.

Följande antaganden fås:

$$u \sim N(0, G), \quad e \sim N(0, R). \quad Cov(u, e) = 0$$

Den totala variansen blir (kovariansmatrisen)

$$V = ZGZ' + R$$

EN GLMM modell tillåter icke-normala utfall (t.ex Binomial, Poisson) alltså från valfri exponentialfamilj. Den använder då en länkfunktion t.ex logit länken.

Den enklaste hierarkiska modellen: Varianskomponentmodell

Den enklaste hierarkiska modellen är en Varianskomponentmodell och används när endast interceptet får variera inom grupper:

$$y_{ij} = \beta_0 + u_{0j} + \epsilon_{ij}$$

där

- i : individ
- j : grupp

- y_{0j} : slumpmässig avvikelse för grupp j .
- ϵ_{ij} : slumpmässig variation inom grupp.

Modellen har följande antaganden:

$$u_{0j} \sim N(0, \sigma_{u0}^2) \quad \epsilon_{ij} \sim N(0, \sigma_e^2)$$

Den totala variansen blir

$$Var[y_{ij}] = \sigma_{u0}^2 + \sigma_e^2$$

Kovariansen mellan två observationer i samma grupp blir:

$$Cov[y_{1j}, y_{2j}] = \sigma_{u0}^2$$

Hur vet man när man ska använda en GLMM modell eller en Varianskomponentmodell?

- **Varianskomponentmodell/LMM:** används när utfallsvariabeln (Y) är kontinuerlig och man vill modellera skillnader mellan och inom grupper (t.ex elever betyg mellan klasser).
- **GLMM:** används när Y inte är normalfördelad. T.ex
 - Binär (0/1) → logistisk GLMM.
 - Räknevariabel → Poisson GLMM.
 - Andel/Proportion → Binomial GLMM.

Intraclass Correlation (ICCA)

Intraklass korrelation är ett mått på hur stor del av variansen beror på gruppnivån:

$$\rho = \frac{\sigma_{u0}^2}{\sigma_{u0}^2 + \sigma_e^2}$$

- Om $\rho \approx 0 \rightarrow$ ingen klusterstruktur (vanlig OLS fungerar).
- Om $\rho > 0 \rightarrow$ klusterstruktur → använd hierarkisk modell.

Anledningen till varför rho endast kan vara 0 eller mer är på grund av att varians aldrig kan vara negativ.

Exempelvis

$$\sigma_{u0}^2 = 0.702 \quad \sigma_e^2 = 1.221$$

Intraklass korrelationen blir då:

$$\rho = \frac{0.702}{0.702 + 1.221} = 0.365$$

→ Cirka **36% av variationen** ligger mellan klasser.

Random Intercept modell vs Random Slope Modell

Random Intercept modell

I en random intercept modell har alla grupper samma lutning med olika intercept. Ekvationsformuleringen blir då:

$$y_{ij} = \beta_0 + \beta_1 x_{ij} + u_{0j} + \epsilon_{ij}$$

Random Slope modell

För en random slope modell kan både intercept och lutning variera mellan grupper. Formuleringen på modellen ändras till:

$$y_{ij} = \beta_0 + \beta_1 x_{ij} + u_{0j} + u_{1j} x_{ij} + \epsilon_{ij}$$

Man antar då att

$$\begin{bmatrix} u_{0j} \\ u_{1j} \end{bmatrix} \sim N \begin{bmatrix} \sigma_{u0}^2 & \sigma_{u01}^2 \\ \sigma_{u10}^2 & \sigma_{u1}^2 \end{bmatrix}$$

Slumpmässiga intercept och lutningar kan dessutom vara korrelerade.

Hur vet man när man ska använda Random intercept eller Random slope modell?

- **Random intercept modell:** Används när man tror att grupperna skiljer sig åt i nivå (medelvärde), men sambandet mellan X och Y är likadant i alla grupper. Exempel: Elever i olika klasser har olika genomsnittlig popularitet, men effekten av utåtvändhet på popularitet är densamma överallt.
- **Random slope modell:** används när man misstänker att sambandet mellan X och Y skiljer sig mellan grupperna. Det vill säga lutningen för X varierar mellan grupper. Exempel: effekten av utåtvändhet på popularitet är starkare i vissa klasser än andra.

Hur vet man detta i praktiken?

1. **Jämför scatterplot per grupp:** verkar linjerna ha olika lutningar?
2. **Jämför modeller:** Börja med random intercept och testa om random slope förbättrar modellen (med t.ex Likelihood Ratio Test).
3. **Teori:** finns det en rimlig anledning till att tro att sambandet varierar mellan grupper?
 - a. **Tumregel:**
 - i. Olika startnivåer → random intercept.
 - ii. Olika samband (lutning) → random slope

Skattningsmetoder för parametrar i hierarkiska modeller

För att skatta både fixed och random effects modeller används:

- ML (Maximum Likelihood)
- REML (Restricted Maximum Likelihood: denna korrigerar för att variansskattningar annars blir för små. REML ger väntevärdesriktiga skattningar

Skattningarna sker iterativt:

1. Börja med OLS
2. Skatta varianskomponenterna
3. Uppdatera beta

4. Upprepa till konvergens.

Hypotestest för fixed/random effects med Likelihood Ratio Test

För Fixed effects (β)

Vanliga t-test och konfidensintervall används, med standardfel från modellen.

För Random Effects (varianskomponenter)

Man kan inte använda t-test (varianser är alltid ≥ 0) utan man använder:

- **Z-test** vid stora stickprov.
- **Likelihood Ratio Test (LRT):**

$$D = -2(\ln L_0 - \ln L_1)$$

där L_0, L_1 är likelihood under noll- respektive alternativhypotesen.

Vid **REML används LRT ENDAST** för modeller som skiljer sig i random effects, inte fixed.

Hypoteserna:

Man har två modeller som man jämför med där hypoteserna blir

En enklare modell H_0 : T.ex random intercept

En enklare modell H_A : T.ex random intercept+Random slope

Ju större skillnad i **log likelihood** desto mer förbättrar den nya modellen passformen. Om vi förkastar H_0 innebär det att en mer komplex modell är lämplig.



Exempel från föreläsningen

Dataset: 2000 elever i 100 klasser

Variabler: Popularity (Y), sex, extraversion, teacher experience

Modell 1 – Basmodell (random intercept)

$$popularity_{ij} = \beta_0 + u_{0j} + \epsilon_{ij}$$

ICC = 0.365 → stark klusterstruktur

Modell 2 – Lägg till kön (fixed)

$$popularity_{ij} = \beta_0 + \beta_1 sex_{ij} + u_{0j} + \epsilon_{ij}$$

→ Kön har en signifikant effekt.

Modell 3 – Kön även slumpmässig

$$popularity_{ij} = \beta_0 + \beta_1 sex_{ij} + u_{0j} + u_{1j} sex_{ij} + \epsilon_{ij}$$

→ Lutningen för kön varierar något mellan klasser.

Modell 4 – Lägg till extraversion (individnivå)

$$popularity_{ij} = \beta_0 + \beta_1 sex_{ij} + \beta_2 extra_{ij} + u_{0j} + \epsilon_{ij}$$

Modell 5 – Extraversion även slumpmässig

$$popularity_{ij} = \beta_0 + \beta_1 sex_{ij} + \beta_2 extra_{ij} + u_{0j} + u_{2j} extra_{ij} + \epsilon_{ij}$$

→ Både intercept och lutning för extraversion varierar.

Modell 6 – Lägg till klassnivåvariabel (teacher experience)

$$popularity_{ij} = \beta_0 + \beta_1 sex_{ij} + \beta_2 extra_{ij} + u_{0j} + \beta_3 tex_j + \beta_4 tex_j \cdot extra_{ij} + u_{0j} u_{2j} extra_{ij} + \epsilon_{ij}$$
